

Protokoll für die Untersuchung des k-Punktes und des tail-Punktes

0. Ziel der protokollierten Untersuchung

Ziel dieser Untersuchung ist die Lage und Varianz der Lage des k-Punktes und des tail-Punktes darzustellen. Ein Schluss über die Lage der Punkte und ihr Verhältnis soll fundieren welche diskriminierende Funktion die Punkte übernehmen können. Dabei werden Gruppen von Texten verwendet geschrieben in den Sprachen Altgriechisch, Latein, Deutsch, Französisch und Italienisch verwendet. Die Auswahl ist willentlich, aber unbegründet.

Verwendung der Ergebnisse in den Schriften: "**Untersuchung zu tokenisieren anhand resultierender token-Mengen**" und "**Die Häufigkeitsverteilung von Wortformen (Token) als Fingerabdruck eines Autors am Beispiel von Herodot und Thukydides**". LINKs:

1. Vorbereitung und Organisation

Empfehlung	Notiz / Beispiel
Festlegung einer einheitlichen Ordnerstruktur	Ergebnisse: gemacht: "zweite_untersuchung_k-Punkt-tail-Punkt" - Ergebnisse werden nach Benennung gespeichert, als file flach im Ordner Diagramme: Korpus:
Aufstellung der Eingabe	
Absicherung des Datenzugangs (Referenz auf DFG Papier)	nur lokaler Ordner
Verwendung konsistenter und sprechender Datei- / Ordnerbenennungen	stylo-ah-online, im "Naming" bereich folgendes eingestellt: explanation_k-punkt_final_0_2026-03-24_kahl
Konsequente Versionierung erheblicher Änderungen	Versoinierug über die Versionsnummer, erste Version = 0
Festlegung eines dauerhaften Speicherorts mit PID	
Dokumentation der Auswahlkriterien für Texte, Bilder, Artefakte	- Korpora werden nach Sprache zusammengestellt, - es sind Korpora aus Texten (Format txt, XML) - nur kuratierte Texte Kodierung der Korpusprache über ID ID: 0 - Altgriechisches Korpus (8 Texte) ID: 1 - Französisch modern (20 Texte) ID: 2 - Latein (15 Texte) ID: 3 - Deutsch (20 Texte) ID: 4 - Italienisch (20 Texte)

Festlegung, welches Material in die Analyse eingeht	- Zur Untersuchung der geschriebenen Zeichen sollen nur alle Zeichen, die zum Inhalt des Textes beitragen untersucht werden
Trennung von Rohdaten, bearbeiteten Daten und Ergebnissen	- Rohdaten sind alle Bestandteile des Korpus - bearbeitete Daten werden in CSV Dateien, wie oben benannt angegeben
Editions- und Datentransparenz:	
<i>Angabe der verwendeten Edition oder digitalen Textquelle (Teubner, OCT, Perseus, TLG, OGL, First-1k)</i>	
<i>Dokumentation der verwendeten Textfassung oder Version (Editionsjahr, Datenbankversion)</i>	
<i>Dokumentation der Behandlung von Varianten (Ausschluss kritischer Apparate)</i>	
<i>Angabe von Transkriptionssystemen (EpiDoc, Beta Code, Unicode)</i>	
<i>Festlegung der Lizenz</i>	

2. Analyseschritte

Empfehlung	Notiz / Beispiel
Dokumentation der Normalisierungsschritte (z.B. Orthographie, Lemmatisierung)	
Dokumentation Zerlegung des Textes (z.B. Tokenisierung) inkl. Begründung (z.B. Wortformen, Lemmata, n-Gramme)	Buchstabendreigramme
Dokumentation Segmentierung der Texte (z.B. Satz, Absatz, Werk)	keine,
Dokumentation der Art der Visualisierung (z.B. Frequenzanalyse, PCA)	Zur Darstellung der Punkt, die in den Token-Verteilungen zum Text ermittelt werden, kommt das Balkendiagramm zum Einsatz. Die Ergebnisse, CSV Liste der Punkte, werden mit Libre Office weiterverarbeitet
Dokumentation Auswahl des Analysealgorithmus (z.B. Distanzmaße, wie Kosinus, Burrows' Delta)	- Token und Histogramm der verschiedenen Token in den Texten, auch Token-Verteilung genannt
Speicherung der Konfiguration (z.B. Parameter, Skripte)	- Speicherung unter dem oben angegebenen Namen zur Verwendung
Prüfung der Stabilität der Ergebnisse (z.B. Variation von Parametern)	Da es sich um die Zählung von Token handelt sind die Ergebnisse auf eine bestimmte Weise der Normalisierung und Tokenisierung bezogen, für diese ist ihre

	Verhalten charakteristisch.
--	-----------------------------

3. Auswertung

Empfehlung	Notiz / Beispiel
Verknüpfung der Einzelprotokolle zur Gesamtdokumentation (z.B. Zusammenführung der Analysedurchläufe)	
Explizite Angabe von Werkzeugen, Skripten und Versionen (z.B. Software, Bibliotheken)	stylo-ah-online libre office calc
Aufstellung der Ergebnisdateien	Export der CSV Listen und der Config Dateien (stylo-ah-online): SELHAULON_explanation_k-punkt_final_1_2026-03-24_0_kahl.styloahonline.csv, SELHAULON_explanation_tail-k-punkt_final_0_2026-03-24_0_kahl.styloahonline.csv, SELHAULON_explanation_tail-k-punkt_final_2_2026-03-24_0_kahl.styloahonline.csv, SELHAULON_explanation_tail-k-punkt_final_3_2026-03-24_0_kahl.styloahonline.csv, SELHAULON_explanation_tail-k-punkt_final_4_2026-03-24_0_kahl.styloahonline.csv, styloahonlineconfig_explanation_k-punkt_final_1_2026-03-24_0_kahl.styloahonline.config, styloahonlineconfig_explanation_tail-k-punkt_final_0_2026-03-24_0_kahl.styloahonline.config, styloahonlineconfig_explanation_tail-k-punkt_final_2_2026-03-24_0_kahl.styloahonline.config, styloahonlineconfig_explanation_tail-k-punkt_final_3_2026-03-24_0_kahl.styloahonline.config, styloahonlineconfig_explanation_tail-k-punkt_final_4_2026-03-24_0_kahl.styloahonline.config Ergebnis-Diagramme als SVG Datei (Benennung: Sprache, Diagramm-Y-Achse, ID): altgriechisch_k-punkt_id-0.svg, altgriechisch_tail-k-position-absolut_id-0.svg, altgriechisch_tail-punkt_id-0.svg,

	deutsch_k-punkt_id-3.svg, deutsch_tail-k-position-absolut_id-3.svg, deutsch_tail-punkt_id-3.svg, franzoesisch_k-punkt_id-1.svg, franzoesisch_tail-k-position-absolut_id-1.svg, franzoesisch_tail-punkt_id-1.svg, italienisch_k-punkt_id-4.svg, italienisch_tail-k-position-absolut_id-4.svg, italienisch_tail-punkt_id-4.svg, latein_k-punkt_id-2.svg, latein_tail-k-position-absolut_id-2.svg, latein_tail-punkt_id-2.svg
Verknüpfung der Tools	- aus stylo-ah-online gewinnen wir die Berechnung der Punkte - tail und k-punkt - mit libre office calc erstellen wir ein Diagramm der beiden Punkte pro Text - Frage zu diesen Diagrammen, wie stabil sind die Punkte in Bezug auf die Anzahl verschiedener Token und untereinander - Bilder wurden exportiert und im Ordner "..." abgespeichert
Vergleich der Ergebnisse bei Variation der Einstellungen (z.B. Prüfung von Stabilität und Robustheit)	Variiert wird lediglich über die Sprachen

4. Replikation und Sicherung

Empfehlung	Notiz / Beispiel
Dokumentation aller Einstellungen und Entscheidungen innerhalb der Analyse (z. B. Parameter, Filter, Auswahlkriterien)	
Angabe der verwendeten Werkzeuge, Skripte und Softwareversionen (inkl. Versionsnummern)	
Festlegung, welche Rohdaten, bearbeiteten Daten und Ergebnisdaten weitergegeben werden können (Berücksichtigung rechtlicher und ethischer Rahmenbedingungen)	
Übergabe der Rohdaten, bearbeiteten Daten und Ergebnisdaten an ein geeignetes Repositorium (z. B. institutionelle oder fachliche Repositorien)	github repo
Benennung von Grenzen, Unsicherheiten und möglichen Fehlerquellen der Analyse (Dokumentation der methodischen Einschränkungen)	